



RAG & Agentic RAG

정원국

텔러스 AI 대표

저작권 안내

(주)업스테이지가 제공하는 모든 교육 콘텐츠의 지식재산권은
운영 주체인 (주)업스테이지 또는 해당 저작물의 적법한 관리자에게 귀속되어 있습니다.

콘텐츠 일부 또는 전부를 복사, 복제, 판매, 재판매 공개, 공유 등을 할 수 없습니다.

유출될 경우 지식재산권 침해에 대한 책임을 부담할 수 있습니다.

유출에 해당하여 금지되는 행위의 예시는 다음과 같습니다.

- 콘텐츠를 재가공하여 온/오프라인으로 공개하는 행위
- 콘텐츠의 일부 또는 전부를 이용하여 인쇄물을 만드는 행위
- 콘텐츠의 전부 또는 일부를 녹취 또는 녹화하거나 녹취록을 작성하는 행위
- 콘텐츠의 전부 또는 일부를 스크린 캡처하거나 카메라로 촬영하는 행위
- 지인을 포함한 제3자에게 콘텐츠의 일부 또는 전부를 공유하는 행위
- 다른 정보와 결합하여 Upstage Education의 콘텐츠임을 알아볼 수 있는 저작물을 작성, 공개하는 행위
- 제공된 데이터의 일부 혹은 전부를 Upstage Education 프로젝트/실습 수행 이외의 목적으로 사용하는 행위

RAG & Agentic RAG

RAG(Retrieval Augmented Generation)의 기본적인 컨셉에 대해 이해하고, 이를 Agent에 어떻게 적용시키는지 알 수 있습니다.

RAG (Retrieval Augmented Generation)

What is RAG?


LLM은 사전 학습된 지식을 기반으로 답변을 생성합니다. RAG는 데이터베이스에서 추가 정보를 검색함으로써 생성된 응답의 정확성과 관련성을 크게 향상시키는 전략이라고 할 수 있습니다.

- **The Retrieval**

- 검색 엔진에 질문을 하면, 검색 엔진은 유사성 검색을 사용하여 방대한 벡터 임베딩 지식 기반을 탐색합니다.

- **The Generation**

- 관련성 있는 정보들을 추출하였다면, 해당 정보를 종합하고 자연어로 표현하여 최종 답변을 도출해야 합니다.




[1] <https://qdrant.tech/articles/what-is-rag-in-ai/>

RAG (Retrieval Augmented Generation)

Indexing


데이터를 벡터 데이터베이스에서 검색하기 쉬운 방식으로 구성합니다.

- **Loader** - 데이터가 포함된 문서 수집
- **Splitter** - 문서를 문장, 단락과 같은 더 작은 단위로 나눕니다. 짧은 텍스트 조각(Snippets, Chunks)가 검색을 해오기에 더 효과적이기 때문입니다.
- **Embedding Machine** - 텍스트를 벡터 임베딩으로 변환합니다. 이를 통해 유사한 정보를 효과적으로 검색해 올 수 있습니다.



RAG (Retrieval Augmented Generation)


Indexing



[2]

RAG (Retrieval Augmented Generation)


Indexing



[2]

RAG (Retrieval Augmented Generation)

Indexing




RAG (Retrieval Augmented Generation)

Query vectorization

Knowledge Base를 벡터화하였다면 사용자 쿼리에도 동일한 작업을 수행할 수 있습니다.

Query Translation 전략 예시

- Query Expansion - 동의어 질문 추가
- Query Decomposition - 복잡한 질문을 분해
- Query Rewrite - 모호화 제거
- HyDE(Hypothetical Document Embeddings)



RAG (Retrieval Augmented Generation)

HYDE




Figure 1: An illustration of the HyDE model. Documents snippets are shown. HyDE serves all types of queries without changing the underlying GPT-3 and Contriever/mContriever models.

RAG (Retrieval Augmented Generation)

Search


검색은 크게 키워드 검색과 의미 검색으로 분류할 수 있고, 이 둘 모두를 활용한 하이브리드 검색을 진행할 수 있습니다.

- **Keyword Search**

- 단어 일치에 중점을 두는 검색 방식입니다.
- 대부분이 0으로 이루어진 Sparse Vector를 사용하여 검색합니다. (ex. BM25)


- **Semantic Search**

- 의미 맥락적 표현의 유사도에 중점을 두는 검색 방식입니다.
- Dense Vector를 사용하여 검색합니다.



RAG (Retrieval Augmented Generation)


Generator



[6]

RAG (Retrieval Augmented Generation)


Generator



[6]

RAG (Retrieval Augmented Generation)

Generator



[6]

Agentic RAG


RAG v.s. Agentic RAG

- **RAG**

- 외부 지식 소스를 활용하여 LLM에 관련 맥락을 제공하고 오류 발생을 줄이는 것.
- 질문 ➡ 검색 ➡ 생성

- **Agentic RAG**

- 검색 구성 요소에서 Agent를 사용하는 것을 의미합니다.
- Perceive ➡ Reason/Plan ➡ Act ➡ Observe



[7]



Building intelligence for the future of work