



Memory Management & Reflexion

정원국

텔러스 AI 대표

저작권 안내

(주)업스테이지가 제공하는 모든 교육 콘텐츠의 지식재산권은
운영 주체인 (주)업스테이지 또는 해당 저작물의 적법한 관리자에게 귀속되어 있습니다.

콘텐츠 일부 또는 전부를 복사, 복제, 판매, 재판매 공개, 공유 등을 할 수 없습니다.

유출될 경우 지식재산권 침해에 대한 책임을 부담할 수 있습니다.

유출에 해당하여 금지되는 행위의 예시는 다음과 같습니다.

- 콘텐츠를 재가공하여 온/오프라인으로 공개하는 행위
- 콘텐츠의 일부 또는 전부를 이용하여 인쇄물을 만드는 행위
- 콘텐츠의 전부 또는 일부를 녹취 또는 녹화하거나 녹취록을 작성하는 행위
- 콘텐츠의 전부 또는 일부를 스크린 캡처하거나 카메라로 촬영하는 행위
- 지인을 포함한 제3자에게 콘텐츠의 일부 또는 전부를 공유하는 행위
- 다른 정보와 결합하여 Upstage Education의 콘텐츠임을 알아볼 수 있는 저작물을 작성, 공개하는 행위
- 제공된 데이터의 일부 혹은 전부를 Upstage Education 프로젝트/실습 수행 이외의 목적으로 사용하는 행위


Memory Management

Agent에서의 Memory 의미에 대해 알고, 장단기에 따른 Memory 관리 기법과 Reflexion에 대해 알아보는 시간을 갖습니다.

Memory Management

Memory

Agent에서 메모리란 과거의 상호작용, 관찰, 학습 경험에서 얻은 정보를 유지하고 활용하는 능력을 의미합니다.




[1] <https://docs.langchain.com/oss/python/langgraph/memory#short-term-memory>

Memory Management

Memory

일반적으로 두 가지 주요 유형으로 분류됩니다.


- **Short Term Memory**
맥락적 메모리 (Contextual Memory)
- **Long Term Memory**
영구적 메모리 (Persistent Memory)



Memory Management

Short Term Memory


- **최근 메시지 (Historical Message)**
 - 유저, 에이전트의 메시지
 - 도구의 사용 결과
- **성찰 (Reflection)**
 - 현재 상호작용에 대한 Agent의 성찰



Memory Management

Short Term Memory


- 관리 방안
 - 잘라내기 (Trim)
 - 요약하기 (Summarize)
 - 체크포인트 관리 (Manage Checkpoint)



Memory Management

Long Term Memory


- 의미 기억(Semantic Memory)
 - 사용자에게 대한 정보, Profile, Persona etc
- 일화 기억(Episodic Memory)
 - 과거 Agent의 행동, Few Shot etc
- 절차 기억(Procedural Memory)
 - 규칙, System Prompt etc



Memory Management

Long Term Memory


- 의미 기억(Semantic Memory)
 - 사용자에게 대한 정보, Profile, Persona etc
- 일화 기억(Episodic Memory)
 - 과거 Agent의 행동, Few Shot etc
- 절차 기억(Procedural Memory)
 - 규칙, System Prompt etc



Memory Management

Long Term Memory


- 의미 기억(Semantic Memory)
 - 사용자에게 대한 정보, Profile, Persona etc
- 일화 기억(Episodic Memory)
 - 과거 Agent의 행동, Few Shot etc
- 절차 기억(Procedural Memory)
 - 규칙, System Prompt etc



Memory Management

Long Term Memory


- 의미 기억(Semantic Memory)
 - 사용자에게 대한 정보, Profile, Persona etc
- 일화 기억(Episodic Memory)
 - 과거 Agent의 행동, Few Shot etc
- 절차 기억(Procedural Memory)
 - 규칙, System Prompt etc



Memory Management

Long Term Memory

- 관리 방안
 - Reflection, Meta Prompting
 - Extraction - Update (ex. Mem0)



Memory Management


사례 1) Mem0

- **Extraction Phase**

- Latest Exchanges
- Rolling Summary
- the m most recent messages

- **Update Phase**


- **ADD** new memories
- **UPDATE** new memories
- **DELETE** contradictions
- **NOOP** if no change is needed



[4]

Memory Management


사례 1) Mem0



[4]

Memory Management

사례 1) Mem0



Memory Management

사례 2) Vertex AI Memory Bank


GCP + Gemini + Managed Memory SaaS

- **Short Term Memory (Sessions)**

- user (특정 사용자)
- app (애플리케이션의 모든 사용자)
- temp (휘발성 메모리)

- **Long Term Memory (Memory Bank)**

- 핵심 정보, 선호도 및 맥락 정보 추출 및 새로운 기억 생성 (in Async / background)



[5] <https://cloud.google.com/blog/products/ai-machine-learning/vertex-ai-memory-bank-in-public-preview?hl=en>

Memory Management

사례 2) Vertex AI Memory Bank


GCP + Gemini + Managed Memory SaaS

- **Short Term Memory (Sessions)**

- user (특정 사용자)
- app (애플리케이션의 모든 사용자)
- temp (휘발성 메모리)

- **Long Term Memory (Memory Bank)**

- 핵심 정보, 선호도 및 맥락 정보 추출 및 새로운 기억 생성 (in Async / background)



Memory Management

사례 2) Vertex AI Memory Bank


GCP + Gemini + Managed Memory SaaS

- **Short Term Memory (Sessions)**

- user (특정 사용자)
- app (애플리케이션의 모든 사용자)
- temp (휘발성 메모리)

- **Long Term Memory (Memory Bank)**

- 핵심 정보, 선호도 및 맥락 정보 추출 및 새로운 기억 생성 (in Async / background)



[5] <https://cloud.google.com/blog/products/ai-machine-learning/vertex-ai-memory-bank-in-public-preview?hl=en>

Memory Management


사례 3) Claude Code

• Short Term Memory

- Context Window에 메시지 추가
- 토큰 개수 확인
- 일정 Threshold 이상 쌓이면 ($\geq 92\%$)
메시지 요약 진행 (Auto-Compact)
- 마지막 3 Turn Message와 Summary만 보존


• Long Term Memory

- 개인, 프로젝트, 로컬, 시스템 전용 장기메모리 불러오기 (CLAUDE.md)
- System Prompt에 작성




Memory Management

사례 3) Claude Code



Memory Management

사례 3) Claude Code




Reflexion

Agent에서의 Memory 의미에 대해 알고, 장단기에 따른 Memory 관리 기법과 Reflexion에 대해 알아보는 시간을 갖습니다.

Reflexion


Why Reflexion?



Reflexion

Why Reflexion?

- **Compression**
 - 지식의 압축
- **Conflict Resolution**
 - 정보의 갱신과 우선순위 판단
- **Implicit Insight**
 - 단서 연결 및 맥락 정보 업데이트
- **Self-Correction**
 - 언어적 피드백과 자기 성찰을 통한 학습
 - 피드백을 반영한 절차 기억 업데이트




[7]

Reflexion


Claude Diary

- **/diary Command (Explicit Memory)**
 - 성과, 디자인 결정, 도전 과제, 사용자 선호도, PR 피드백 등 주요 세션 세부사항
 - 로드된 Claude Code 세션
- **/reflect Command (Implicit Memory)**
 - 클로드 코드가 일기 항목을 분석하고 CLAUDE.md 업데이트를 생성
 - 반복되는 패턴을 식별
 - 다이어리 항목에 캡처된 많은 패턴(커밋 스타일, 테스트, 코드 품질)이 보편적으로 적용



Reflexion


Claude Diary



[7]

Reflexion

Claude Diary



[7]



Building intelligence for the future of work