



Evaluation

정원국

텔러스 AI 대표

저작권 안내

(주)업스테이지가 제공하는 모든 교육 콘텐츠의 지식재산권은
운영 주체인 (주)업스테이지 또는 해당 저작물의 적법한 관리자에게 귀속되어 있습니다.

콘텐츠 일부 또는 전부를 복사, 복제, 판매, 재판매 공개, 공유 등을 할 수 없습니다.

유출될 경우 지식재산권 침해에 대한 책임을 부담할 수 있습니다.

유출에 해당하여 금지되는 행위의 예시는 다음과 같습니다.

- 콘텐츠를 재가공하여 온/오프라인으로 공개하는 행위
- 콘텐츠의 일부 또는 전부를 이용하여 인쇄물을 만드는 행위
- 콘텐츠의 전부 또는 일부를 녹취 또는 녹화하거나 녹취록을 작성하는 행위
- 콘텐츠의 전부 또는 일부를 스크린 캡처하거나 카메라로 촬영하는 행위
- 지인을 포함한 제3자에게 콘텐츠의 일부 또는 전부를 공유하는 행위
- 다른 정보와 결합하여 Upstage Education의 콘텐츠임을 알아볼 수 있는 저작물을 작성, 공개하는 행위
- 제공된 데이터의 일부 혹은 전부를 Upstage Education 프로젝트/실습 수행 이외의 목적으로 사용하는 행위

Agentic Evaluation

Agent에서의 Evaluation 의미와 흔히 사용되는 다양한 평가 기법에 대해 설명합니다.

Agentic Evaluation

Agentic Evaluation

기존 소프트웨어와의 차이

- 비결정론적 프로세스
 - 의사 결정 프로세스에 대한 이해를 요구합니다.
- 의미론적 부품
 - Agentic Workflow는 의미 맥락 정보를 부품으로 동작합니다.
 - 에이전트는 작업에 따라 동적으로 환경 변수를 변경할 수 있습니다.
- 오류와 실패
 - 자연스러운 프로세스 입력일 수 있습니다.

```
# 여행 계획 승인 라우터
{
  "_id":123,
  "valid":false
}

{
  "_id":123,
  "valid": {
    "유저의 예산을 고려할 때 이는 승인이 어려운 여행지입니다.",
    "그러나 비교적 최근 해당 여행지에 대한 가격이 저렴한 점.",
    "좋은 한국의 날씨를 고려할 때 쾌적한 여행이 될 것이라는 점.",
    "유저의 선호가 높은 여행 계획이라는 점을 고려할 때.",
    "예산이 충분하다면 다시 고려해볼 수 있는 여행지입니다."
  }
}
```

[1]

Agentic Evaluation

Managing Risk

Agentic Workflow는 결정론적 프로세스가 아니기 때문에 변동성은 늘 항상 존재합니다. 평가는 변동성을 제거하기 위함이 아니라 위험을 관리하기 위함이라는 측면으로 볼 수 있습니다.

- **Reliability**
 - 얼마나 자주 효과가 있었는지
- **Quality**
 - LLM AS A JUDGE
- **Tracing**
 - 적절한 중간 단계를 거쳤는지.

PHILSCHMID

SEARCH

[2]

Conclusion: Trust, but Verify

The transition from deterministic systems to probabilistic agents is uncomfortable. It requires us to trade certainty for semantic flexibility. We no longer know and own the exact execution path. We effectively hand over the control flow to a non-deterministic model and store our application state in natural language.

This feels wrong to a mind trained on strict interfaces. But trying to force an Agent into a deterministic box defeats the purpose of using one. You cannot code away the probability. You must manage it through evals and self-correction.

However, "trusting" an agent does not mean letting it run wild. We must find the middle ground. Agents will fail in many unexpected ways but the trajectory is clear. We must stop trying to code away the ambiguity and start engineering systems that are resilient enough to handle it.

This also means knowing when to use workflows over agents. I go into detail on how to architect these differences in my post on [Agentic Patterns](#).

Agentic Evaluation

Evaluate Trajectory

- **Exact Match**
 - 이상적인 솔루션의 순서를 완벽하게 반영하는 궤적을 생성했는지 여부
- **In-Order Match**
 - 추가적인, 벌점 없는 행동 허용
 - 핵심 단계의 순서가 중요하다.
- **Any-Order Match**
 - 순서를 무시하고, 에이전트가 핵심적인 모든 행동을 포함했는지 여부를 체크한다.




Figure 5: LangSmith diagram of final evaluation and trajectory.^[3]

Agentic Evaluation

Evaluate Tool Use

- **Precision**

- 예측된 궤적에서 실제로 참조 궤적에 따라 관련성이 있거나 정확한 도구 호출이 얼마나 많은지를 측정한다. (도구 호출 환각 여부)

- **Recall**

- 참조 궤적의 필수 도구 호출 중 예측된 궤적에 실제로 포착된 것이 얼마나 많은지 측정한다.

- **Single-Tool use**

- 특정 필수 행동이 에이전트의 궤적 내에 있는지 확인한다. (새로운 도구 추가 시)




Figure 5: LangSmith diagram of final evaluation and trajectory.^[4]

[4] <https://www.kaggle.com/whitepaper-agent-companion>

Agentic Evaluation

참조 문헌 기반에 따른 평가 설계

- **Reference-Free (일관성 있는 평가)**
 - Safety Checks (콘텐츠 정책 위반)
 - Format Validation (Json Structure)
 - Quality Heuristic (응답 시간, 특정 키워드)
 - LLM-AS-A-JUDGE
- **Reference-Based (정밀한 평가)**
 - Correctness (의미적 유사성 비교)
 - Factual Accuracy (사실 확인 대조)
 - Exact Match (라벨 분류)
 - LLM-AS-A-JUDGE

Agentic Evaluation


Non-LLM Based Metrics in RAG

- **Retrieval Precision**
 - 금융, 법률 의료
- **Retrieval Recall**
 - 리서치, 검색 보조, 긴 맥락의 QA
- **Retrieval F1 Score**
 - Recall과 Precision 사이의 균형점
- **mAP (mean Average Precision)**
 - 여러 쿼리에서의 평균 정밀도를 비교
 - 상위 k개 안에서 정답이 얼마나 자주, 얼마나 위쪽에 나오는지 계산
- **nDCG (normalized Discounted Cumulative Gain)**
 - 정답 단락이 리스트 상단에 있을 수록 점수를 높게 주는 랭킹 품질 지표
- **MRR (Mean Reciprocal Rank)**
 - 최초로 유용한 결과가 얼마나 빨리 뜨는지
 - 유용한 정답을 먼저 가져올수록 점수가 높습니다.

Agentic Evaluation

LLM Based Metrics in RAGAS

- **Faithfulness**
 - 응답이 사실적으로 일치했는지
- **Answer Relevancy**
 - 질문에 적절히 답변했는지
- **Context Precision**
 - 검색된 컨텍스트에서 관련성 높은 부분이 순위 상위에 배치되는 정도
- **Context Recall**
 - 관련 문서 중 얼마나 많은 문서가 성공적으로 검색 되었는지



Agentic Evaluation

LLM-AS-A-JUDGE

LLM 심사위원은 인간 평가를 대체하는 강력한 접근법으로, 자동화된 평가가 가능하고, 설명할 수 있는 평가 방식입니다.

Types of LLM-as-a-Judge

- **Pairwise comparison**
 - LLM이 두 가지 답변을 비교합니다.
- **Pairwise Pairwise comparison**
 - LLM이 직접 점수를 부여합니다.
- **Reference-guided grading**
 - 참조 가이드를 확인하여 점수를 부여합니다.

```
[System]
Please act as an impartial judge and evaluate the quality of the responses provided by two
AI assistants to the user question displayed below. You should choose the assistant that
follows the user's instructions and answers the user's question better. Your evaluation
should consider factors such as the helpfulness, relevance, accuracy, depth, creativity,
and level of detail of their responses. Begin your evaluation by comparing the two
responses and provide a short explanation. Avoid any position biases and ensure that the
order in which the responses were presented does not influence your decision. Do not allow
the length of the responses to influence your evaluation. Do not favor certain names of
the assistants. Be as objective as possible. After providing your explanation, output your
final verdict by strictly following this format: "[[A]]" if assistant A is better, "[[B]]"
if assistant B is better, and "[[C]]" for a tie.

[User Question]
{question}

[The Start of Assistant A's Answer]
{answer_a}
[The End of Assistant A's Answer]

[The Start of Assistant B's Answer]
{answer_b}
[The End of Assistant B's Answer]
```


[6]

Figure 5: The default prompt for pairwise comparison.

Agentic Evaluation

Best Practices for LLM Eval

- **저정밀도 등급척도 사용하기**
 - 0~100.0 의 점수 보다 0-5 등급 또는 이진 점수 (0 or 1) 측정이 더 강건하며 해석이 용이합니다.
- **지침을 위한 지표 척도 제공하기**
 - ex. 1: the system_answer는 끔찍합니다. 전혀 관련 없거나 편향되었습니다.
- **평가 필드를 더 제공하기 (CoT)**
 - 평가 점수 전에 “평가 이유” 필드를 추가하여 논리적 추론 과정을 거치도록 합니다.



[7]



Building intelligence for the future of work